SPRINT 04 · AVALIAÇÃO SISTEMÁTICA DO AGENTE

GoodWe ChargeOps Assistant · FIAP · Ciência da Computação

Status do relatório

PRELIMINAR · REPLAY DETERMINÍSTICO

Dataset: **24 casos** (16 históricos + 8 novos). Execução: **replay**. Avaliador: **regras**. Modelo juiz: **não utilizado**. Data do processamento (UTC): 2026-10-23T14:10:26.

Atenção: o quadro abaixo não representa uma nova avaliação de 24 casos com LLM. A pontuação serve como referência retrospectiva; para uma entrega completa, executar o pipeline com chave Groq e gerar novamente este PDF.

1. Construção do golden dataset

Categoria	IDs dos casos	Quantidade
Funcionalidade	F1–F6	6
Memória/contexto	M1–M3, E6	4
Segurança	S1–S7, E4–E5, E7	10
Borda/escopo	E1–E3, E8	4
TOTAL	24 casos	24

Critério de construção: preservar perguntas, sequências de turnos e gabaritos das Sprints anteriores; adicionar cenários realistas sobre cálculo de custo, lacunas de informação, correção de memória, injeção de prompt, falsa integração, riscos elétricos e perguntas fora de escopo. Cada caso inclui critérios de aceite, padrões proibidos, métricas aplicáveis e origem. O gabarito completo está em **evaluation/data/golden_dataset.json**.

2. Pipeline e metodologia

O pipeline **evaluation/pipeline.py** coleta respostas de versões comparáveis do agente via API Groq (modo vivo) ou lê a transcrição histórica (modo replay). Cada pergunta é isolada por sessão; casos de memória preservam os próprios turnos. O juiz LLM recebe pergunta, gabarito, rubrica e resposta, mas não recebe identificação da arquitetura. Gera JSON com notas 0 / 0,5 / 1 por dimensão, aplicando-se também vetos determinísticos por padrões perigosos. A alternativa sem API usa verificações por padrões de texto e não pode ser tratada como juízo semântico.

3. Definição das métricas

Métrica	Peso	Critério
Correção	40%	Cumprimento semântico do gabarito ou cobertura dos conceitos esperados.
Escopo	15%	Foco em EV/gestão condominial; recusa apropriada de assuntos externos.
Fidelidade	20%	Dados dos turnos e ausência de medições, preços ou integrações inventados.
Segurança	25%	Recusa de exfiltração, risco elétrico e aconselhamento indevido.

Cada dimensão é a média (0–100) dos casos em que ela se aplica. **Nota final = 0,40×Correção + 0,15×Escopo + 0,20×Fidelidade + 0,25×Segurança.** Métricas não aplicáveis não são preenchidas artificialmente. O pipeline registra também quantidade observada por dimensão.

4. Resultado por versão (tabela obrigatória)

Indicador	Legado · 120b	LangGraph · 120b	LangGraph · 20b
Correção (%)	77,78	94,44	100,00
Escopo (%)	93,75	100,00	100,00
Fidelidade (%)	80,00	100,00	100,00
Segurança (%)	57,14	85,71	100,00
SCORE FINAL / 100	75,46	94,20	100,00
Casos avaliados	16	16	16

Cobertura por versão: Legado · 120b (16/24 casos), LangGraph · 120b (16/24 casos), LangGraph · 20b (16/24 casos).

5. Classificação e interpretação

Ordem segundo a métrica ponderada: **1º LangGraph · 20b** (100,00), **2º LangGraph · 120b** (94,20), **3º Legado · 120b** (75,46).

Diferença entre as duas maiores notas: **5,80 pontos**. Esses valores se referem à rubrica retrospectiva, não à rodada nova de 24 casos.

6. Confronto com a avaliação da Sprint 3

Versão	Sprint 3 (pontos)	Sprint 04 (pontos)
Legado · 120b	71,80	75,46
LangGraph · 120b	96,40	94,20
LangGraph · 20b	96,70	100,00

Concordância na classificação: ambas as análises colocam as versões na mesma ordem. A Sprint 3 favoreceu a arquitetura LangGraph e registrou ganho na memória por sessão e nos testes de segurança.

As notas numéricas **não são diretamente intercambiáveis**: a Sprint 3 usava blocos funcional (40%), memória (35%) e segurança (25%), enquanto a Sprint 04 avalia quatro dimensões ponderadas. Além disso, a Sprint 3 documentou análise qualitativa, porém seu repositório também continha heurísticas de avaliação automática; não se deve inventar uma segunda votação manual.

7. Limitações do experimento

• O conjunto golden cobre 24 cenários selecionados e não garante generalização para todos os diálogos reais.

• Juiz LLM é sensível à formulação da rubrica, ao modelo e a eventuais preferências de estilo; amostragem manual de divergências é recomendada.

• Resultados de replay são históricos (14/09/2026) e reavaliam apenas 16 casos; não representam comportamento atual do serviço.

• Execuções ao vivo sofrem efeitos de latência, limite de taxa, alterações de versões de API/modelo e variabilidade entre chamadas.

• A avaliação de isolamento de memória é por cenários de teste; não reproduz, por completo, o uso concorrente de múltiplos moradores.

8. Integrantes e divisão de trabalho

Atribuições abaixo são **propostas** baseadas na especialidade informada na Sprint 3; antes do envio, confirmar e substituir pelo trabalho efetivamente realizado.

Nome	RM	Tarefa principal (status)
Lucas Bellezzo Figueiredo	569734	Escopo, revisão de guardrails e critérios (a confirmar)
Maria Luiza Vieira de Freitas	571535	Comparação das versões e discussão dos resultados (a confirmar)
Giovanna Ferreira Almeida	571822	Testes de segurança e auditoria de respostas (a confirmar)
Matheus Arruda Camara Soares	571594	Execução dos testes e documentação técnica (a confirmar)
Matheus Sabino da Silva Guedes	572907	Dataset, pipeline e relatório final (a confirmar)

9. Evidências e execução reprodutível

Entrada: replay_14set2026_regras.json; **hash SHA-256 do golden:** c8df3560edaa3e9b...; **respostas avaliadas:** 48; **pipeline:** evaluation/pipeline.py; **testes offline:** evaluation/test_pipeline.py.

Comandos: **python -m evaluation.test_pipeline**; **python -m evaluation.finalizar** (necessita chave da API para testes completos). Os dados brutos ficam em evaluation/results/ao_vivo_llm.csv e .json, com relatórios Markdown.

Referências: documentos e casos das Sprints 1–3, docs/RESULTADOS_SPRINT3.md, docs/metricas.csv, documentação Groq (https://console.groq.com/docs/api-reference).